# Kế hoạch thực hiện bài tập UNSW-NB15

Phát hiện xâm nhập mạng với Random Forest và Gradient Boosting · làm theo bài báo *Random Forest-Based Network Intrusion Detection with Feature Selection and Class Balancing on UNSW-NB15 Traffic* (Information, MDPI, 2026, 17(9), 836)

## 1. Cách đọc bản kế hoạch này

- **Quỹ thời gian: 4 giờ mỗi tuần**, chia thành **2 buổi × 2 giờ**: Thứ Bảy và Chủ Nhật. Nếu bận hai ngày này, đổi sang ngày khác, nhưng giữ thứ tự buổi và để cách nhau ít nhất một ngày khi có tác vụ chạy nền.
- **Mục tiêu 8 tuần** (16 buổi, xong Chủ Nhật 6/12). **Tuần 9–10** (12–20/12) là vùng đệm: trễ thì làm bù ở đây; kịp thì dùng để làm phần mở rộng và luyện tập thêm. Nếu cô có hạn nộp sớm hơn thì cắt theo mục 3.
- Mỗi buổi chia thành các khung thời gian (giờ:phút từ lúc bắt đầu buổi). Cuối buổi có ô **Kết quả cuối buổi**: không đạt ô này thì ghi lại vào log và chuyển phần còn thiếu sang buổi sau.
- Đây là kế hoạch, không có code. Tên hàm và tham số chỉ để biết cần viết gì.

## 2. Bốn quy tắc để 4 giờ/tuần đủ dùng

- **Chạy nền không tính vào 4 giờ.** Huấn luyện là việc máy làm. Cuối buổi, khởi chạy script rồi đi làm việc khác; đầu buổi sau thu kết quả. Nhờ vậy 2 giờ của mỗi buổi dành cho việc cần đầu óc.
- **Lưu xác suất dự đoán của mọi lần chạy** (validation và held-out), cùng nhãn thật. Các phần chỉnh ngưỡng, đường Precision–Recall và chi phí ở tuần 7 chỉ dùng lại file này mà không phải huấn luyện lại.
- **Mỗi buổi dành 5 phút cuối để ghi log** (file log.md): đã làm gì, kết quả gì, buổi sau làm gì. Đầu buổi sau đọc dòng cuối log là biết bắt đầu từ đâu.
- **Cố định mọi thứ như bài:** random_state=10, RandomizedSearchCV với n_iter=10, cv=3, scoring=f1. Cố gắng cài cùng phiên bản thư viện với bài (scikit-learn 1.3.0, imbalanced-learn 0.11.0) nếu cài được.

## 3. Luật cắt khi bị trễ (cắt từ trên xuống)

- Bỏ phần Gradient Boosting có SMOTE (giữ GB không SMOTE).
- Rút gọn lưới k của GB còn {10, 20, 35} (ghi rõ trên slide đây là khác bài).
- Chỉ chạy GB cho 3 loại: DoS, Analysis, Backdoor (là ba loại biến động nhất trong bài).
- Gộp buổi 4 và buổi 5 (phân tích dữ liệu), bớt một nửa số biểu đồ.
- **Không được cắt:** phân tích dữ liệu cốt lõi, tái lập Random Forest, phần phân tích bỏ sót theo recall, và slide. Đây là những phần đáp ứng trực tiếp yêu cầu của cô.

## 4. Tổng quan 8 tuần

| Tuần | Ngày | Nội dung chính | Mốc phải đạt cuối tuần |
|---|---|---|---|
| 1 | 17–18/10 | Đọc bài, dựng môi trường, nạp dữ liệu | Sơ đồ pipeline + notebook nạp được dữ liệu |
| 2 | 24–25/10 | Phân tích dữ liệu 1–2: nhãn, biến phân loại, biến số | 6–8 hình, 6 phát hiện |
| 3 | 31/10–1/11 | Phân tích 3 (tương quan, MI, train vs test), tiền xử lý, chia dữ liệu, slide phần dữ liệu | Dữ liệu đã chia khớp bài + 5–6 slide nháp |
| 4 | 7–8/11 | Pipeline Random Forest, tìm tham số, chạy DoS | DoS chạy xong toàn bộ vòng k |
| 5 | 14–15/11 | Đối chiếu DoS với bài, RF không SMOTE 5 loại, bắt đầu SMOTE | Bảng RF không SMOTE |
| 6 | 21–22/11 | RF có SMOTE, so sánh, slide RF, thiết lập Gradient Boosting | RF tái lập xong + 4–5 slide; GB chạy nền |
| 7 | 28–29/11 | GB xong, bảng RF vs GB, PR curve, ngưỡng theo recall, chi phí, phân tích bỏ sót | 2 kết quả mới có số liệu |
| 8 | 5–6/12 | Hoàn thiện slide, luyện tập | **Hạn mục tiêu 8 tuần.** Bộ slide + kịch bản |
| 9–10 | 12–20/12 | Vùng đệm và mở rộng | Làm bù hoặc mở rộng tuỳ tiến độ |

## 5. Kế hoạch chi tiết theo buổi

### TUẦN 1 · 17–18/10

**Mục tiêu:** hiểu rõ bài báo; có môi trường và dữ liệu sẵn sàng.
**Mốc cuối tuần:** sơ đồ pipeline và notebook nạp được dữ liệu.

| BUỔI 1 · Thứ Bảy 17/10 · Đọc bài báo, nắm pipeline · 2 giờ | |
|---|---|
| **0:00–0:20** | Đọc Introduction và Conclusions. Viết tóm tắt đúng 5 dòng: bài toán, dữ liệu, cách làm, kết quả chính, hạn chế. |
| **0:20–1:05** | Đọc kỹ Section 3 (Materials and Methods). Vẽ sơ đồ pipeline bằng tay: lọc nhị phân (Normal + một loại tấn công) → label encoding → (SMOTE) → SelectKBest bằng mutual information, k ∈ {5, 10, ..., 35} → RandomizedSearchCV → chỉnh ngưỡng trên validation → đánh giá trên held-out. Ghi riêng các tham số cố định: random_state=10, n_iter=10, cv=3, scoring=f1; SMOTE nâng lớp thiểu số lên 56,000 mẫu; tập test chính thức chia 30% validation / 70% held-out. |
| **1:05–1:40** | Đọc Section 4. Đối chiếu Phụ lục A của file này với Table 3, 5, 8 trong bài gốc và sửa nếu thấy chép sai. |
| **1:40–1:55** | Đọc mục 5.1 (Limitations). Ghi 4 hạn chế sẽ dùng làm chỗ cho phần kết quả mới: (1) chỉ có Random Forest, không có boosting; (2) ngưỡng tối ưu theo F1 chứ không theo recall; (3) luồng đã lọc theo từng loại tấn công nên có thể lạc quan; (4) chỉ một seed, không có khoảng tin cậy. |
| **1:55–2:00** | Ghi log. Viết 3 câu còn chưa hiểu. |
| **Kết quả cuối buổi** | 1 trang ghi chú tóm tắt + sơ đồ pipeline + 3 câu hỏi. |

| BUỔI 2 · Chủ Nhật 18/10 · Môi trường và nạp dữ liệu · 2 giờ | |
|---|---|
| **0:00–0:25** | Chọn nơi chạy: máy cá nhân nếu đủ RAM (nên ≥ 8 GB) vì chạy nền ổn định hơn; Colab dễ bị ngắt phiên nên phải lưu kết quả sau mỗi vòng. Cài pandas, numpy, scikit-learn, imbalanced-learn, matplotlib, seaborn. Tạo thư mục data/, notebooks/, src/, results/, figures/, slides/ và git init. |
| **0:25–0:50** | Lấy dữ liệu: hai file train và test chính thức của UNSW-NB15 (link ở mục Supplementary Materials và Data Availability của bài). Mở thử xem. |
| **0:50–1:20** | Nạp dữ liệu. In shape (đối chiếu 175,341 dòng ở train và 82,332 dòng ở test), dtypes, vài dòng đầu. Xác định cột nào là id, nhãn nhị phân (label), nhãn loại tấn công (attack_cat). Liệt kê các giá trị của attack_cat. |
| **1:20–1:45** | Đọc file mô tả đặc trưng đi kèm bộ dữ liệu. Ghi chú ngắn ý nghĩa của các đặc trưng hay gặp (dur, proto, service, state, sbytes, dbytes, rate, sttl...). |
| **1:45–2:00** | Viết file log.md đầu tiên và quy ước lưu kết quả ở Phụ lục C. Ghi log. |
| **Kết quả cuối buổi** | Notebook 01_nap_du_lieu chạy được từ đầu đến cuối; bảng ghi chú các cột. |

## TUẦN 2 · 24–25/10

**Mục tiêu:** phân tích dữ liệu: chất lượng, nhãn, biến phân loại, biến số.
**Mốc cuối tuần:** 6–8 hình đã lưu và danh sách 6 phát hiện.

| BUỔI 3 · Thứ Bảy 24/10 · Phân tích dữ liệu 1: chất lượng và nhãn · 2 giờ | |
|---|---|
| **0:00–0:25** | Kiểm tra giá trị thiếu, dòng trùng, kiểu dữ liệu. Quyết định xử lý và ghi lý do. Bỏ cột id. **Lưu ý:** attack_cat là nhãn nên không được đưa vào đặc trưng. |
| **0:25–0:55** | Phân bố label (0/1) và attack_cat trên train và trên test. Làm bảng số và biểu đồ cột. Đối chiếu train với Table 2 của bài (DoS 12,264; Exploit 33,393; Backdoor 1,746; Analysis 2,000; Reconnaissance 10,491). |
| **0:55–1:25** | Tính tỉ lệ mất cân bằng của từng loại tấn công so với Normal trong train. Kiểm tra một giả thuyết: con số 56,000 mà bài dùng cho SMOTE có trùng với số bản ghi Normal ở train không? Nếu trùng thì SMOTE ở đây nâng lớp tấn công lên cân bằng với Normal. |
| **1:25–1:50** | Làm 2 hình sạch cho slide (nhãn nhị phân; 9 loại tấn công), đặt tên file rõ ràng trong figures/. |
| **1:50–2:00** | Ghi 3 phát hiện đầu tiên. Ghi log. |
| **Kết quả cuối buổi** | 2–3 hình + 3 phát hiện về nhãn và mất cân bằng. |

| BUỔI 4 · Chủ Nhật 25/10 · Phân tích dữ liệu 2: biến phân loại và biến số · 2 giờ | |
|---|---|
| **0:00–0:35** | Ba biến phân loại proto, service, state: số giá trị khác nhau, các giá trị phổ biến, tỉ lệ tấn công theo từng giá trị. Chú ý giá trị hiếm và giá trị chỉ xuất hiện ở train hoặc chỉ ở test (sẽ gặp lúc encoding). |
| **0:35–1:15** | Biến số: thống kê mô tả, độ lệch (skew); histogram thang log cho 4–6 đặc trưng có phân phối lệch nặng (ví dụ dur, sbytes, dbytes). |
| **1:15–1:50** | Boxplot hoặc violin của 4–6 đặc trưng chính theo từng loại tấn công so với Normal. Nhận xét loại nào dễ tách, loại nào chồng lấn. |
| **1:50–2:00** | Ghi 3 phát hiện nữa. Ghi log. |
| **Kết quả cuối buổi** | 3–4 hình + tổng cộng 6 phát hiện. |

## TUẦN 3 · 31/10–1/11

**Mục tiêu:** hoàn tất phân tích; chuẩn bị dữ liệu cho mô hình; dựng slide phần dữ liệu.
**Mốc cuối tuần:** dữ liệu đã chia khớp kích thước trong bài + 5–6 slide nháp.

| BUỔI 5 · Thứ Bảy 31/10 · Phân tích dữ liệu 3: tương quan, MI, train vs test · 2 giờ | |
|---|---|
| **0:00–0:35** | Ma trận tương quan (heatmap) trên các đặc trưng số; liệt kê các cặp có tương quan rất cao (ví dụ $\|r\| > 0.95$) và nhận xét ý nghĩa với mô hình cây. |
| **0:35–1:10** | Mutual information của đặc trưng với từng bài toán nhị phân (Normal vs DoS, vs Exploit, ...) trên dữ liệu đã encode. Lấy top 15 đặc trưng cho mỗi loại, làm bảng so sánh giữa các loại. |
| **1:10–1:45** | So sánh train và test: tỉ lệ các lớp và phân phối của 3–4 đặc trưng. Kiểm tra xem có lệch phân phối hay không, không giả định trước. |
| **1:45–2:00** | Ghi các phát hiện. Ghi log. |
| **Kết quả cuối buổi** | Heatmap, bảng top MI, hình train vs test. |

| BUỔI 6 · Chủ Nhật 1/11 · Tiền xử lý, chia dữ liệu, slide phần dữ liệu · 2 giờ | |
|---|---|
| **0:00–0:40** | Viết hàm lọc nhị phân (giữ Normal + một loại tấn công, bỏ các loại khác ở cả train, validation, held-out) và hàm label encoding cho proto, service, state: fit trên train, xử lý giá trị lạ ở test (ví dụ gán một mã riêng). |
| **0:40–1:05** | Chia tập test chính thức thành validation 30% và held-out 70% với random_state=10. Kiểm tra kích thước held-out theo Phụ lục A: Normal khoảng 25,900 và số tấn công từng loại (DoS 2,862; Exploit 7,793; Backdoor 408; Analysis 474; Reconnaissance 2,447). Các số này khớp với việc chia có phân tầng theo lớp; nếu số của mày khớp thì cách chia đúng. |
| **1:05–1:15** | Lưu dữ liệu đã xử lý ra file (ví dụ parquet hoặc csv) để các buổi sau chỉ việc nạp. |
| **1:15–2:00** | Mở template HUST (Blue 16×9) và dựng 5–6 slide: yêu cầu của cô và bài toán; bộ dữ liệu; phân bố nhãn và mất cân bằng; biến phân loại/biến số; tương quan và MI; train vs test. Mỗi slide một thông điệp, dùng hình đã lưu. |
| **Kết quả cuối buổi** | Dữ liệu đã chia khớp Phụ lục A; 5–6 slide nháp. |

## TUẦN 4 · 7–8/11

**Mục tiêu:** dựng pipeline Random Forest và chạy trọn vẹn một loại tấn công (DoS).
**Mốc cuối tuần:** vòng k của DoS chạy nền xong.

| BUỔI 7 · Thứ Bảy 7/11 · Pipeline Random Forest cơ bản trên DoS · 2 giờ | |
|---|---|
| **0:00–0:50** | Viết pipeline: (SMOTE tuỳ chọn) → SelectKBest(mutual information, k) → RandomForestClassifier. Chạy DoS không SMOTE với k=15, tham số mặc định, ngưỡng 0.5. Mục đích là pipeline chạy thông, chưa cần sát số của bài. |
| **0:50–1:20** | Chỉnh ngưỡng trên validation: quét 0.05–0.95, chọn ngưỡng tối đa F1. Tính precision, recall, F1 và TP/FP/FN/TN trên held-out. **Lưu xác suất dự đoán** của validation và held-out cùng nhãn thật. |
| **1:20–1:50** | Vẽ confusion matrix (số và tỉ lệ theo hàng) giống Table 8. So với DoS không SMOTE của bài (F1 0.9468, FN 211, FP 87). |
| **1:50–2:00** | Ghi chênh lệch và các nghi vấn vào log. |
| **Kết quả cuối buổi** | Một lần chạy DoS hoàn chỉnh, có confusion matrix, đã lưu xác suất. |

| BUỔI 8 · Chủ Nhật 8/11 · RandomizedSearchCV, vòng k, script chạy nền · 2 giờ | |
|---|---|
| **0:00–0:40** | Thêm RandomizedSearchCV: n_iter=10, cv=3, scoring=f1, random_state=10. Không gian: n_estimators {100, 200, 300, 400}, min_samples_leaf {1, 2, 3}, max_features {None, 'sqrt'}, class_weight {None, 'balanced'}. |
| **0:40–1:10** | Thêm vòng for k trong {5, 10, 15, 20, 25, 30, 35}. Mỗi k: search → ngưỡng trên validation → metric trên held-out → ghi một dòng vào CSV. Lưu xác suất của cấu hình tốt nhất. **Ghi kết quả ngay sau mỗi k** để bị ngắt giữa chừng không mất hết. |
| **1:10–1:30** | Chạy thử k=5 với n_iter=2 để chắc không lỗi và đo thời gian. Từ đó ước lượng tổng thời gian cho 7 giá trị k. |
| **1:30–1:50** | Đóng gói thành hàm chạy_cho(loại_tấn_công, smote) và một script .py chạy ngoài notebook. |
| **1:50–2:00** | Khởi chạy DoS không SMOTE đầy đủ. Ghi log. |
| **Kết quả cuối buổi** | Script chạy nền hoạt động. |
| **Chạy nền** | DoS không SMOTE, 7 giá trị k. Để chạy đến buổi sau. |

## TUẦN 5 · 14–15/11

**Mục tiêu:** tái lập Random Forest không SMOTE cho cả 5 loại tấn công.
**Mốc cuối tuần:** bảng RF không SMOTE so với Table 3; các job SMOTE đã khởi chạy.

| BUỔI 9 · Thứ Bảy 14/11 · Đối chiếu DoS, chạy 4 loại còn lại · 2 giờ | |
|---|---|
| **0:00–0:30** | Đọc kết quả DoS. So với bảng mục tiêu (F1 0.9468; k=15; FN 211; FP 87). Mức lệch chấp nhận được gợi ý: trong khoảng 0.01–0.02 F1. Lệch nhiều hơn thì dùng danh sách kiểm tra ở Phụ lục B. |
| **0:30–1:00** | Sửa lỗi nếu có và chạy lại DoS khi cần (chỉ cần chạy lại cấu hình tốt nhất để kiểm tra). |
| **1:00–1:20** | Khởi chạy Backdoor, Analysis, Reconnaissance, Exploit (không SMOTE) tuần tự trong một script. Exploit nặng nhất nên đặt cuối. |
| **1:20–2:00** | Trong lúc chờ: viết hàm vẽ confusion matrix và bảng tổng hợp tự động từ các file CSV; viết hàm vẽ đường Precision–Recall từ xác suất đã lưu (chuẩn bị cho tuần 7). |
| **Kết quả cuối buổi** | DoS đã đối chiếu; các hàm vẽ và tổng hợp đã có. |
| **Chạy nền** | Backdoor, Analysis, Reconnaissance, Exploit không SMOTE. |

| BUỔI 10 · Chủ Nhật 15/11 · Thu kết quả không SMOTE, khởi chạy SMOTE · 2 giờ | |
|---|---|
| **0:00–0:40** | Thu kết quả 4 loại. Lập bảng RF không SMOTE đặt cạnh Table 3 (k, precision, recall, F1, FN, FP). Ghi chỗ lệch. |
| **0:40–1:10** | Thêm bước SMOTE: nâng lớp thiểu số lên 56,000 mẫu, chỉ áp trên train, thực hiện trước SelectKBest như bài. Chạy thử DoS với n_iter nhỏ để kiểm tra. |
| **1:10–1:30** | Khởi chạy SMOTE cho cả 5 loại, bắt đầu bằng 4 loại nhẹ rồi tới Exploit. |
| **1:30–2:00** | Ghi nhận loại nào lệch bài nhiều nhất và nêu giả thuyết vì sao (có thể là cách chia, encoding, hoặc seed). Ghi log. |
| **Kết quả cuối buổi** | Bảng RF không SMOTE hoàn chỉnh. |
| **Chạy nền** | 5 loại có SMOTE. Còn cả tuần để chạy. |

## TUẦN 6 · 21–22/11

**Mục tiêu:** hoàn tất RF, làm slide RF, thiết lập Gradient Boosting.
**Mốc cuối tuần:** RF tái lập xong + 4–5 slide; GB không SMOTE đã khởi chạy.

| BUỔI 11 · Thứ Bảy 21/11 · So sánh SMOTE, slide Random Forest · 2 giờ | |
|---|---|
| **0:00–0:35** | Thu kết quả SMOTE. Lập bảng F1 có/không SMOTE (kiểu Table 7) và so với bài. |
| **0:35–1:05** | Vẽ 5 cặp confusion matrix (kiểu Table 8). Chú ý đặc biệt Analysis (bài ghi FP tăng từ 11 lên 136 khi dùng SMOTE) và DoS (cả FN và FP giảm). |
| **1:05–2:00** | Dựng 4–5 slide: sơ đồ pipeline; thiết lập thí nghiệm; kết quả RF đặt cạnh số của bài; ảnh hưởng của SMOTE; confusion matrix tiêu biểu. Nếu số của mình lệch bài thì ghi thẳng điều đó và nêu lý do có thể. |
| **Kết quả cuối buổi** | **Mốc B:** Random Forest đã tái lập xong; 4–5 slide RF. |

| BUỔI 12 · Chủ Nhật 22/11 · Gradient Boosting: thiết lập và khởi chạy · 2 giờ | |
|---|---|
| **0:00–0:30** | Thiết kế: dùng đúng pipeline của RF (cùng chia dữ liệu, cùng SelectKBest, cùng cách chỉnh ngưỡng), chỉ thay bộ phân loại. Không gian tham số gợi ý: số cây {100, 200, 300}, learning_rate {0.05, 0.1, 0.2}, max_depth {3, 5}; thêm subsample {0.8, 1.0} nếu dùng GradientBoostingClassifier. Giữ RandomizedSearchCV n_iter=10, cv=3, scoring=f1. |
| **0:30–1:00** | Chạy thử DoS với k=15 và đo thời gian. Nếu GradientBoostingClassifier quá chậm thì đổi sang HistGradientBoostingClassifier hoặc rút lưới k còn {10, 20, 35}. Ghi rõ lựa chọn này để đưa lên slide. |
| **1:00–1:30** | Mở rộng hàm chạy_cho(mô_hình, loại_tấn_công, smote) cho cả hai họ mô hình. |
| **1:30–2:00** | Khởi chạy GB không SMOTE cho cả 5 loại. Ghi log. |
| **Kết quả cuối buổi** | GB đã khởi chạy cho 5 loại. |
| **Chạy nền** | GB không SMOTE, 5 loại. |

## TUẦN 7 · 28–29/11

**Mục tiêu:** so sánh RF với GB và tạo kết quả mới theo hướng hạn chế bỏ sót.
**Mốc cuối tuần:** ít nhất 2 kết quả mới, có hình và số.

| BUỔI 13 · Thứ Bảy 28/11 · Thu GB, bảng so sánh, đường PR · 2 giờ | |
|---|---|
| **0:00–0:35** | Thu kết quả GB. Lập bảng RF vs GB cho 5 loại: precision, recall, F1, FN, FP, thời gian huấn luyện. Ghi loại nào GB hơn, loại nào kém. Giải thích chỉ ở mức giả thuyết, không khẳng định. |
| **0:35–1:05** | Vẽ đường Precision–Recall của RF và GB cho từng loại từ xác suất đã lưu (không phải huấn luyện lại). |
| **1:05–1:25** | Khởi chạy GB có SMOTE cho DoS, Analysis, Backdoor. |
| **1:25–2:00** | Dựng 3 slide: thiết lập GB; bảng so sánh RF vs GB; đường PR. |
| **Kết quả cuối buổi** | Bảng RF vs GB + hình PR + 3 slide. |
| **Chạy nền** | GB có SMOTE cho 3 loại (có thể không kịp, xem tuần 8). |

| BUỔI 14 · Chủ Nhật 29/11 · Kết quả mới: bỏ sót, ngưỡng, chi phí · 2 giờ | |
|---|---|
| **0:00–0:40** | **Chỉnh ngưỡng theo recall.** Với mỗi loại và mỗi mô hình, chọn trên validation ngưỡng đạt recall mục tiêu (thử 0.95, 0.98, 0.99), rồi đo trên held-out: recall, FN, FP, precision trước và sau. Mục đích là chỉ ra cái giá phải trả về precision/FP. |
| **0:40–1:10** | **Cost-sensitive.** Đặt chi phí một FN bằng c lần chi phí một FP, c ∈ {1, 5, 10, 20}. Với mỗi c, chọn ngưỡng tối thiểu hoá tổng chi phí trên validation, báo tổng chi phí trên held-out. **Nói rõ c là giả định** của nhóm, không phải số liệu thật. |
| **1:10–1:45** | **Phân tích mẫu bị bỏ sót (FN)** của loại khó nhất (trong bài là Analysis, recall 0.8924): so phân phối vài đặc trưng và proto/service/state giữa mẫu bị bỏ sót và mẫu bắt đúng. |
| **1:45–2:00** | Lập bảng nháp theo từng loại: FN, recall, hậu quả nếu bỏ sót. Việc xếp loại nào nghiêm trọng hơn là nhận định của nhóm, phải nêu lý do. Ghi log. |
| **Kết quả cuối buổi** | **Mốc C:** 2 kết quả mới (ngưỡng theo recall + chi phí hoặc phân tích FN) có hình và số. |

## TUẦN 8 · 5–6/12

**Mục tiêu:** hoàn thiện slide và luyện tập. Đây là hạn của mục tiêu 8 tuần.
**Mốc cuối tuần:** bộ slide hoàn chỉnh, kịch bản nói, đã tập ít nhất một lần.

| BUỔI 15 · Thứ Bảy 5/12 · Hoàn thiện slide · 2 giờ | |
|---|---|
| **0:00–0:30** | Thu GB có SMOTE nếu đã xong (không xong thì bỏ, ghi rõ chưa chạy). Cập nhật bảng so sánh. **Đóng băng số liệu** từ lúc này: không chạy thêm thí nghiệm. |
| **0:30–1:30** | Dựng các slide còn lại theo storyboard ở Phụ lục D: ngưỡng theo recall, chi phí, phân tích bỏ sót và mức nghiêm trọng, hạn chế, kết luận, bài báo đã chọn và lý do chọn (tóm tắt phần đã kiểm tra độ uy tín), tài liệu tham khảo. |
| **1:30–2:00** | Rà soát toàn bộ: một thông điệp mỗi slide, số trên slide khớp CSV, hình có chú thích và đơn vị, font nhất quán theo template. |
| **Kết quả cuối buổi** | Bộ slide bản hoàn chỉnh (18–21 slide). |

| BUỔI 16 · Chủ Nhật 6/12 · Luyện tập và chốt · 2 giờ | |
|---|---|
| **0:00–0:30** | Viết kịch bản nói: mỗi slide 1–2 phút, câu mở đầu và câu chuyển tiếp. |
| **0:30–1:00** | Tập nói lần 1, bấm giờ, ghi chỗ vấp. |
| **1:00–1:30** | Chuẩn bị trả lời 10 câu hỏi phản biện ở Phụ lục E. |
| **1:30–1:50** | Chạy lại một loại tấn công từ đầu để chắc kết quả tái lập được. Sao lưu repo và file slide ở hai nơi. |
| **1:50–2:00** | Chốt và ghi log. |
| **Kết quả cuối buổi** | Slide, kịch bản và repo đều sẵn sàng. |

# 6. Tuần 9–10 (12–20/12): vùng đệm và mở rộng

Bốn buổi này là chỗ để dồn phần bị trễ. Việc nào đang trễ thì làm trước, theo thứ tự ở mục 3. Nếu đã kịp, chọn mở rộng theo thứ tự ưu tiên dưới đây (làm hết cái trên rồi mới sang cái dưới).

| Ưu tiên | Việc | Ước lượng | Vì sao đáng làm |
|---|---|---|---|
| 1 | Luyện tập thêm 2–3 lần, thử trước một người nghe | 1 buổi | Điểm trình bày thường quyết định hơn một chục điểm F1. |
| 2 | Chạy lại cấu hình tốt nhất của RF và GB với 5 seed khác nhau, báo trung bình ± độ lệch chuẩn | 1 buổi, phần lớn là chạy nền | Bài gốc chỉ có một seed và tự nhận là hạn chế. |
| 3 | Đánh giá luồng hỗn hợp: ghép 5 bộ phát hiện chạy trên toàn bộ test không lọc, đặt một quy tắc gộp cảnh báo (ví dụ bất kỳ bộ nào báo thì cảnh báo), đo FP trên Normal và các tấn công khác | 2 buổi | Bài gốc nêu rõ cần làm điều này trước khi nói đến hệ thống thật. |
| 4 | Thêm XGBoost hoặc LightGBM vào cùng pipeline | 1–2 buổi | Chỉ làm nếu còn dư; GB đã đủ đáp ứng yêu cầu. |

## Phụ lục A. Bảng số mục tiêu từ bài báo

Chép từ Table 3, 5 và 8 của bài. Tập held-out có Normal khoảng 25,900 mẫu (25,900–25,901 tuỳ bảng). Cột P là precision, R là recall. Khi chép sang slide, đối chiếu lại với bài gốc.

| Loại | Số mẫu tấn công held-out | Không SMOTE k · P · R · F1 | FN / FP (không SMOTE) | Có SMOTE k · P · R · F1 | FN / FP (có SMOTE) |
|---|---|---|---|---|---|
| DoS | 2,862 | 15 · 0.9682 · 0.9263 · 0.9468 | 211 / 87 | 30 · 0.9717 · 0.9368 · 0.9539 | 181 / 78 |
| Exploit | 7,793 | 35 · 0.9462 · 0.9546 · 0.9504 | 354 / 423 | 35 · 0.9515 · 0.9516 · 0.9516 | 377 / 378 |
| Backdoor | 408 | 25 · 0.9975 · 0.9706 · 0.9839 | 12 / 1 | 10 · 0.9704 · 0.9632 · 0.9668 | 15 / 12 |
| Analysis | 474 | 35 · 0.9747 · 0.8924 · 0.9317 | 51 / 11 | 20 · 0.7635 · 0.9262 · 0.8370 | 35 / 136 |
| Reconnaissance | 2,447 | 35 · 0.9865 · 0.9579 · 0.9720 | 103 / 32 | 30 · 0.9806 · 0.9501 · 0.9651 | 122 / 46 |

Số mẫu tấn công held-out suy ra bằng cách cộng TP và FN trong Table 8. Số mẫu train theo Table 2: DoS 12,264; Exploit 33,393; Backdoor 1,746; Analysis 2,000; Reconnaissance 10,491. Kích thước tập: train 175,341; test chính thức 82,332 (30% validation, 70% held-out).

## Phụ lục B. Danh sách kiểm tra khi số lệch bài

- Kích thước held-out có khớp Phụ lục A không (Normal ≈ 25,900 và số tấn công từng loại)? Nếu không, kiểm tra lại cách chia 30/70 và việc có phân tầng theo lớp hay không.
- Đã loại id, label và attack_cat khỏi đặc trưng chưa? Để sót attack_cat là rò rỉ nhãn, kết quả sẽ đẹp bất thường.
- Đã lọc đúng (chỉ Normal + loại mục tiêu) ở cả train, validation và held-out chưa?
- Label encoding fit trên train, không fit trên test; giá trị lạ ở test được xử lý?
- Ngưỡng chọn trên validation, không chọn trên held-out?
- SMOTE chỉ áp trên train, nâng lớp thiểu số lên 56,000, thực hiện trước SelectKBest?
- random_state=10 ở mọi nơi (chia, SMOTE, RF, search)? Phiên bản scikit-learn và imbalanced-learn có gần với bài không?
- RandomizedSearchCV đúng n_iter=10, cv=3, scoring=f1, và không gian tham số như bài?
- Mức lệch chấp nhận được gợi ý là 0.01–0.02 F1. Với Analysis và các cấu hình có SMOTE, biến động có thể lớn hơn; hãy ghi lại thay vì ép cho khớp.

## Phụ lục C. Quy ước lưu kết quả

- Cấu trúc thư mục: data/, notebooks/, src/, results/, figures/, slides/, log.md.
- Tên file kết quả: results/{mô_hình}_{loại}_{smote hoặc nosmote}_metrics.csv (mỗi dòng một giá trị k: tham số tốt nhất, ngưỡng, precision, recall, F1, TP, FP, FN, TN, thời gian).
- Xác suất: results/{mô_hình}_{loại}_{smote hoặc nosmote}_proba_val.npy, _proba_test.npy, cùng y_val.npy và y_test.npy. Đây là nguyên liệu cho tuần 7.
- log.md: mỗi buổi ba dòng: đã làm, kết quả, buổi sau làm gì. Đầu buổi sau đọc dòng cuối.
- Mỗi cuối buổi git commit, ghi ngắn nội dung.

## Phụ lục D. Storyboard slide (18–21 slide)

| Slide | Nội dung | Làm ở buổi |
|---|---|---|
| 1 | Tiêu đề | 15 |
| 2 | Yêu cầu của cô và bài toán (IDS, bỏ sót có hậu quả nghiêm trọng) | 6 |
| 3 | Bài báo chọn để làm theo và lý do chọn (mới, tạp chí, có code, hạn chế) | 15 |
| 4 | Bộ dữ liệu UNSW-NB15 | 6 |

| Slide | Nội dung | Làm ở buổi |
|---|---|---|
| 5–9 | Phân tích dữ liệu: nhãn và mất cân bằng; biến phân loại; biến số; tương quan và MI; train vs test | 6 |
| 10–11 | Pipeline và thiết lập thí nghiệm (RF, GB, k, search, ngưỡng, SMOTE) | 11 |
| 12–13 | Kết quả RF so với bài; ảnh hưởng của SMOTE và confusion matrix | 11 |
| 14–15 | Gradient Boosting so với RF; đường Precision–Recall | 13 |
| 16 | Chỉnh ngưỡng theo recall: được gì, mất gì | 15 |
| 17 | Cost-sensitive với c khác nhau | 15 |
| 18 | Phân tích mẫu bị bỏ sót và mức nghiêm trọng theo loại tấn công | 15 |
| 19 | Hạn chế và hướng tiếp theo | 15 |
| 20 | Kết luận | 15 |
| 21 | Tài liệu tham khảo | 15 |

## Phụ lục E. Mười câu hỏi phản biện nên chuẩn bị

- Vì sao không dùng accuracy để đánh giá?
- Vì sao chọn bài báo này, độ uy tín của nó ra sao, và những điểm yếu của nó là gì?
- SMOTE có gây rò rỉ dữ liệu không? Nó được áp ở đâu trong pipeline?
- Ngưỡng quyết định được chọn trên tập nào? Vì sao không chọn trên held-out?
- Vì sao chọn Random Forest và Gradient Boosting? Điểm khác nhau cơ bản của hai mô hình là gì?
- Kết quả của nhóm có hơn bài không? Có so sánh trực tiếp được không, vì sao?
- Hệ số chi phí c lấy từ đâu? Nếu c thay đổi thì kết luận có đổi không?
- Bài toán lọc nhị phân từng loại tấn công khác gì với một hệ thống IDS thật?
- Những hạn chế của UNSW-NB15 là gì?
- Nếu có thêm thời gian thì làm gì tiếp?